

东北大学资源与土木工程学院

平时作业报告

课程名称：地理时空信息大数据

学生专业：测绘工程

学生班级：测绘 2301

学 号：20232444

学生姓名：闻子博

指导教师：郭甲腾 舒阳

作业成绩：

教师评语：

评阅人：

评阅时间：

摘要

作业以“纽约市黄色出租车订单数据”为专题地理时空大数据案例，围绕课程要求中的数据获取、清洗、处理、统计、代码编写和作业报告撰写开展完整实践。研究以 2025 年 10 月 TLC 黄色出租车订单为核心数据源，结合 Taxi Zone 空间分区、Taxi Zone Lookup 分区对照表和 OpenStreetMap 兴趣点（POI）数据，构建了包含时间、空间、OD 流向和城市功能要素的多源数据分析流程。

在数据处理方面，作业首先对原始订单数据进行字段筛选、时间解析、缺失值剔除、异常时长控制、异常距离控制和异常费用控制，最终保留有效订单 4,135,152 条，覆盖 263 个 Taxi Zone 空间分区，其中具有有效上车或下车记录的分区为 261 个。在统计分析方面，作业构建了分区上车量、分区下车量、24 小时订单量、星期—小时订单量、OD 流向、POI 数量和单位面积服务密度等指标。

在可视化方面，作业利用 Python 和 ArcGIS 完成折线图、柱状图、上车量/下车量分级设色图、POI 核密度图、OD 高频流向图、相关性矩阵热力图、功能区对比图和典型功能区空间识别图等多类型图件。结果显示，纽约市黄色出租车活动具有显著昼夜周期和空间中心集聚特征，曼哈顿核心区、机场枢纽和综合功能区是出租车活动高值区域；POI 分析表明，酒店旅游点和餐饮商业点与出租车活动强度具有较强联系，功能区差异是解释出租车热点形成的重要因素。

关键词：地理时空大数据；纽约市出租车；数据清洗；Taxi Zone；OD 流向；POI；空间统计；可视化

Summary

The assignment takes "New York City Yellow Taxi Order Data" as the special geographical spatio-temporal big data case, and carries out complete practice around data acquisition, cleaning, processing, statistics, code writing and assignment report writing in the course requirements. The study takes TLC yellow taxi orders in October 2025 as the core data source, combined with Taxi Zone spatial partition, Taxi Zone Lookup partition comparison table and OpenStreetMap point of interest (POI) data, and constructs a multi-source data analysis process including time, space, OD flow direction and urban functional elements.

In terms of data processing, the job first performs field screening, time analysis, missing value elimination, abnormal duration control, abnormal distance control and abnormal expense control on the original order data, and finally retains 4,135,152 valid orders, covering 263 Taxi Zone space partitions, of which There are 261 partitions with valid boarding or alighting records. In terms of statistical analysis, the operation constructed indicators such as zoning boarding volume, zoning dropping volume, 24-hour order volume, week-to-hour order volume, OD flow direction, POI quantity and service density per unit area.

In terms of visualization, the homework uses Python and ArcGIS to complete line charts, histograms, loading/unloading hierarchical coloring charts, POI kernel density charts, OD high-frequency flow diagrams, correlation matrix heat maps, functional area comparison charts and typical functional area spatial recognition maps and other types of maps. The results show that the yellow taxi activity in new york has the characteristics of obvious day and night cycle and spatial center agglomeration, and the core area of Manhattan, airport hub and comprehensive functional area are the high-value areas of taxi activity. POI analysis shows that hotel tourist spots and restaurant commercial spots have a strong relationship with taxi activity intensity, and the difference of functional areas is an important factor to explain the formation of taxi hotspots.

Keywords: geographical spatio-temporal big data; New York City Taxi; Data cleaning; Taxi Zone; OD flow direction; POI; Spatial statistics; Visualization

目录

一、作业背景与研究目标	1
二、数据获取与数据说明	2
三、数据清洗与质量控制	3
四、时空处理与统计指标构建	4
五、代码编写与实现过程	6
六、统计分析结果与图表表达	9
七、专题地图与空间可视化成果	11
7.1 上车量空间分布图	11
7.2 下车量空间分布图	13
7.3 高频 OD 流向图	14
7.4 地铁站 POI 空间分布密度图	15
7.5 餐饮商业 POI 空间分布密度图	16
7.6 酒店旅游 POI 空间分布密度图	17
7.7 POI 数量对比图	18
7.8 相关性矩阵热力图	19
7.9 典型功能区空间识别图	21
八、结论与展望	25
九、主要成果文件与代码说明	26
参考资料	27
附录：数据清洗 python 代码	28

一、作业背景与研究目标

地理时空信息大数据强调以空间位置、时间过程和属性信息为核心，对城市运行、资源环境、交通出行和社会经济活动进行综合刻画。本次平时作业要求围绕一个专题开展地理时空大数据的获取、清洗、处理和统计分析，并完成代码编写与作业报告撰写。结合课程主题和数据可获取性，本作业选择“基于纽约市出租车订单数据的城市时空出行热点识别与功能区差异分析”作为实践对象。

出租车订单数据是一类典型的城市交通时空大数据。每一条订单通常同时包含时间信息、空间信息和属性信息，例如上车时间、下车时间、上车分区、下车分区、行程距离、费用和支付方式等。与传统问卷调查或抽样交通调查相比，出租车订单数据具有样本量大、连续性强、时空分辨率高和行为链条完整等优势，适合用于识别城市活动热点、分析 OD 流向、刻画高峰时段和解释不同城市功能区的出行差异。

本作业的总体目标是：基于纽约市 2025 年 10 月黄色出租车订单数据，完成专题地理时空大数据从原始获取到统计结果输出的完整流程。具体包括：（1）获取出租车订单、Taxi Zone 空间分区、Taxi Zone Lookup 对照表和 OSM POI 辅助数据；（2）对订单数据进行缺失值、异常时长、异常距离和异常费用的清洗；（3）构建小时、星期、分区上车量、分区下车量和 OD 流向等统计指标；（4）结合 POI 数据开展功能要素解释；（5）利用 Python 和 ArcGIS 完成图表、专题地图和动态可视化成果；（6）总结出租车活动的时间规律、空间热点、OD 联系和功能区差异。



图 1 技术路线图：专题地理时空大数据处理流程

二、数据获取与数据说明

本作业采用“核心订单数据 + 空间分区数据 + 城市功能 POI 数据”的多源数据组织方式。其中，核心数据为纽约市出租车与豪华车管理委员会（TLC）发布的 2025 年 10 月黄色出租车订单数据；空间分区数据为 TLC Taxi Zone 空间面与 Taxi Zone Lookup 对照表；辅助解释数据为 OpenStreetMap 兴趣点数据，包括地铁站点、餐饮商业点和酒店旅游点。

表 1 数据来源、文件名称与主要用途

数据类型	文件名称	数据来源	主要用途
黄色出租车订单数据	yellow_tripdata_2025-10.parquet	TLC Trip Record Data	订单清洗、时间分析、OD 统计、热点识别
分区对照表	taxi_zone_lookup.csv	TLC Taxi Zone Lookup	LocationID 与行政区、Zone 名称匹配
空间分区数据	taxi_zones.shp	TLC Taxi Zone Shapefile	ArcGIS 专题制图、空间连接、面积计算
地铁站 POI	nyc_subway_station.geojson	OpenStreetMap / Overpass	交通换乘功能解释
餐饮商业 POI	nyc_food_shop.geojson	OpenStreetMap / Overpass	商业消费与服务业功能解释
酒店旅游 POI	nyc_hotel_tourism.geojson	OpenStreetMap / Overpass	旅游接待与住宿功能解释

TLC 订单数据中的关键字段包括 tpep_pickup_datetime 、 tpep_dropoff_datetime 、 PULocationID 、 DOLocationID 、 trip_distance 、 passenger_count、payment_type、fare_amount、tip_amount 和 total_amount。其中，PULocationID 表示上车 Taxi Zone 编号，DOLocationID 表示下车 Taxi Zone 编号，是连接订单数据与空间分区文件的核心字段。

表 2 黄色出租车订单核心字段说明

字段	含义	用途
tpep_pickup_datetime	上车时间	构建小时、日期、星期和高峰时段指标
tpep_dropoff_datetime	下车时间	计算行程时长并进行异常值控制
PULocationID	上车分区编号	统计上车热点和 OD 起点
DOLocationID	下车分区编号	统计下车热点和 OD 终点
trip_distance	行程距离	识别距离为零或极端距离异常订单
total_amount	总费用	识别费用为零或极端费用异常订单
passenger_count	乘客数量	辅助描述订单属性
payment_type	支付方式	辅助分析出租车属性特征

OSM POI 数据主要用于解释城市功能要素对出租车出行热点的影响。地铁站点代表交通换乘功能，餐饮商业点代表商业消费和服务业活动，酒店旅游点代表旅游接待和住宿功能。通过将 POI 点数据统计到 Taxi Zone 分区内，可以进一步比较不同功能区的出租车活动差异。

三、数据清洗与质量控制

原始出租车订单数据虽然样本量大，但不可直接用于统计分析。实际数据中可能存在时间缺失、上车或下车分区缺失、行程距离为零、费用为零、行程时长异常、极端距离和极端费用等问题。如果不进行清洗，这些异常记录会影响小时订单量、分区上车量、下车量和 OD 流向等统计结果的可靠性。因此，本作业在统计前首先构建了较为严格的数据清洗规则。

表 3 订单数据清洗规则

清洗项目	处理规则	目的
关键字段缺失	删除上下车时间、LocationID、距离、总费用缺失记录	保证核心字段完整
行程时长异常	trip_duration_min <= 0 的记录剔除	避免错误时间差导致无效行程
距离异常	trip_distance <= 0 的记录剔除	去除无实际空间移动的无效订单
费用异常	total_amount <= 0 的记录剔除	去除无效收费记录
极端值控制	时长≤180 分钟、距离≤100 英里、总费用≤500 美元	降低极端异常值对统计结果影响
分区编号控制	保留有效 LocationID 分区编号	保证可以与 Taxi Zone 空间分区匹配

经过上述清洗后，本作业得到有效订单 4,135,152 条，覆盖 263 个 Taxi Zone 空间分区，其中有有效上车或下车记录的分区为 261 个。该数据规模较大，既能够体现“地理时空信息大数据”的数据量特征，也能够支撑后续统计分析和空间可视化工作。

清洗过程的关键在于构建行程时长字段。行程时长由下车时间减去上车时间得到，单位统一转换为分钟。其计算公式为：

$$trip_{duration_{min}} = \frac{(tpep_{dropoff_{datetime}} - tpep_{pickup_{datetime}})}{60}$$

其中，时间差原始单位为秒，除以 60 后转化为分钟。该字段不仅可以用于识别异常订单，也可以作为后续行程效率、出行行为或交通拥堵分析的基础指标。

四、时空处理与统计指标构建

完成数据清洗后，需要将单条订单记录转换为适合统计分析和地图表达的分区级指标。本作业采用 Taxi Zone 作为空间统计单元，以小时、星期和分区编号作为主要聚合维度，构建了分区上车量、分区下车量、24 小时订单量、星期—小时订单量和 OD 流量等指标。

设第 k 条订单的上车分区为 $PULocationID_k$ ，下车分区为 $DOLocationID_k$ 。第 i 个分区的上车量可以表示为：

$$T_i^{PU} = \sum I(PULocationID_k = i)$$

第 i 个分区的下车量可以表示为：

$$T_i^{DO} = \sum I(DOLocationID_k = i)$$

其中， $I(\cdot)$ 为指示函数。当条件成立时取 1，否则取 0。OD 流量用于描述起点分区 i 到终点分区 j 之间的订单数量，可以表示为：

$$F_{ij} = \sum I(PULocationID_k = i \text{ 且 } DOLocationID_k = j)$$

为了进一步解释出租车热点与城市功能要素之间的关系，本作业还统计了每个分区内的地铁站数量、餐饮商业点数量和酒店旅游点数量，并计算 POI 总量。相关性分析采用 Pearson 相关系数，其公式为：

$$r_{xy} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{[\sum (x_i - \bar{x})^2 \cdot \sum (y_i - \bar{y})^2]}}$$

其中， x_i 可以表示第 i 个分区的出租车上车量或下车量， y_i 可以表示该分区某类 POI 数量。为了消除空间分区面积差异影响，单位面积服务密度指标定义为：

$$D_i = \frac{T_i}{A_i}$$

其中， D_i 表示第 i 个分区单位面积出租车服务密度， T_i 表示该分区上车量或下车量， A_i 表示分区面积。

表 4 指标体系与分析目标

指标类别	具体指标	分析目标
时间指标	pickup_hour、pickup_weekday、is_weekend	识别昼夜周期、工作日差异和高峰时段
空间强度指标	pickup_count、dropoff_count	识别上车热点和下车热点
OD 流向指标	F_{ij} 、flow_count	刻画起点分区到终点分区的联系强度
功能要素指标	subway_cnt、food_cnt、hotel_cnt	解释交通、商业、旅游功能对出租车活动的影响
相关性指标	Pearson r	量化 POI 与出租车活动之间的线性关联
均衡性指标	单位面积订单量 D_i	评价面积归一化后的服务密度差异

五、代码编写与实现过程

本作业的代码实现主要采用 Python 完成，核心流程包括读取 Parquet 订单数据、清洗异常记录、构建时间字段、生成分区统计表、生成小时统计表、构建 OD 流向表，以及输出 CSV 结果文件。ArcGIS 主要负责空间制图、空间连接、核密度图和专题地图输出。Python 代码的优势在于能够高效处理百万级订单记录，并快速形成标准化统计表；ArcGIS 的优势在于空间表达能力强，适合完成分级设色图、POI 密度图和功能区空间识别图。

表 5 Python 代码模块与输出成果

代码模块	主要功能	输出成果
数据读取模块	读取 yellow_tripdata_2025-10.parquet 和 taxi_zone_lookup.csv	形成原始 DataFrame
清洗模块	剔除缺失值、无效时长、无效距离、无效费用和极端值	形成清洗后订单表
时间字段模块	提取日期、小时、星期、周末标识	支撑时间分布统计
分区统计模块	按 PULocationID 和 DOLocationID 分组统计	输出 pickup_by_zone.csv 和 dropoff_by_zone.csv
小时统计模块	按 pickup_hour 和 weekday-hour 分组统计	输出 hourly_orders.csv 和 weekday_hour_orders.csv
OD 统计模块	按 PULocationID-DOLocationID 组合统计	输出 od_top100.csv
可视化模块	生成折线图、柱状图、OD 图、相关性矩阵和 GIF 动图	支撑报告图文表达

下面给出核心代码片段。第一段代码用于读取订单数据、选择关键字段并构建行程时长。为了减少内存压力，仅读取与本作业分析相关的字段，而不是一次性读取所有字段。

```
import pandas as pd

use_cols = [
    "tpep_pickup_datetime", "tpep_dropoff_datetime",
    "PULocationID", "DOLocationID", "trip_distance",
    "passenger_count", "payment_type", "fare_amount",
    "tip_amount", "total_amount"
]

df = pd.read_parquet("yellow_tripdata_2025-10.parquet", columns=use_cols)
df["tpep_pickup_datetime"] = pd.to_datetime(df["tpep_pickup_datetime"],
errors="coerce")
df["tpep_dropoff_datetime"] = pd.to_datetime(df["tpep_dropoff_datetime"],
errors="coerce")
df["trip_duration_min"] = (df["tpep_dropoff_datetime"] -
df["tpep_pickup_datetime"]).dt.total_seconds() / 60
```

第二段代码体现了数据清洗规则。该规则从关键字段完整性、行程时长、行程距离、费用和极端值五个方面控制数据质量。

```
df = df.dropna(subset=[
    "tpep_pickup_datetime", "tpep_dropoff_datetime",
    "PULocationID", "DOLocationID", "trip_distance", "total_amount"
])

df = df[df["trip_duration_min"] > 0]
df = df[df["trip_distance"] > 0]
df = df[df["total_amount"] > 0]
df = df[df["trip_duration_min"] <= 180]
df = df[df["trip_distance"] <= 100]
df = df[df["total_amount"] <= 500]
```

第三段代码用于构建时间字段。通过提取小时、星期和周末标识，可以进一步生成 24 小时订单量曲线、星期—小时多折线图 and 高峰时段统计表。

```

df["pickup_date"] = df["tpep_pickup_datetime"].dt.date
df["pickup_hour"] = df["tpep_pickup_datetime"].dt.hour
df["pickup_weekday"] = df["tpep_pickup_datetime"].dt.dayofweek
df["pickup_weekday_name"] = df["tpep_pickup_datetime"].dt.day_name()
df["is_weekend"] = df["pickup_weekday"].isin([5, 6]).astype(int)

```

第四段代码用于生成分区上车量、分区下车量和 OD 流向表。这里直接利用订单中的 PULocationID 和 DOLocationID 进行分组统计，避免了逐条订单空间落区处理。

```

pickup_by_zone = (
    df.groupby("PULocationID")
      .size()
      .reset_index(name="pickup_count")
      .rename(columns={"PULocationID": "LocationID"})
)

dropoff_by_zone = (
    df.groupby("DOLocationID")
      .size()
      .reset_index(name="dropoff_count")
      .rename(columns={"DOLocationID": "LocationID"})
)

od_table = (
    df.groupby(["PULocationID", "DOLocationID"])
      .size()
      .reset_index(name="flow_count")
      .sort_values("flow_count", ascending=False)
)

```

从代码结构看，本作业不是简单地绘制一两张地图，而是形成了可复现的数据处理链条。只要更换不同月份的 TLC 订单数据，代码即可复用于其他月份出租车时空热点分析；如果更换城市或数据类型，该流程也可迁移到共享单车、网约车或公交刷卡等其他城市交通大数据场景。

六、统计分析结果与图表表达

统计结果首先从时间维度展开。根据 24 小时订单量统计，2025 年 10 月纽约市黄色出租车具有明显的昼夜节律。全天峰值出现在 18 时，订单量达到 276,735 单。凌晨 2 点至 5 点为低谷，6 点以后订单量明显回升，17 点至 21 点保持较高水平，说明傍晚通勤、商务返程、餐饮消费、夜间娱乐和旅游活动共同推高出租车需求。




图 2 2025 年 10 月纽约市黄色出租车 24 小时订单量变化图

表 6 星期订单量统计结果

星期	订单量
周四	715,885
周五	715,562
周三	675,344
周六	577,931
周二	509,629
周日	496,461
周一	444,340




图 3 2025 年 10 月纽约市黄色出租车星期订单量对比图




图 4 2025 年 10 月纽约市黄色出租车工作日一小时订单量变化图

从星期统计结果看，周四和周五的出租车订单量最高，说明工作日后段与周末前城市活动更加活跃。工作日一小时多折线图显示，不同星期均存在凌晨低谷

和傍晚高值，但周五和周六夜间订单相对更高，反映餐饮、娱乐、旅游和社交活动对出租车需求具有明显拉动作用。

七、专题地图与空间可视化成果

专题地图与空间可视化是地理时空大数据分析的重要表达环节。本文在完成出租车订单清洗、分区统计、OD 流向构建和 POI 空间统计的基础上，综合利用 ArcGIS 和 Python 绘制了上车量空间分布图、下车量空间分布图、POI 密度图、OD 流向图、相关性矩阵图和功能区对比图。通过这些图件，可以更加直观地揭示纽约市出租车活动的时间节律、空间热点、功能区差异和服务不均衡特征。

7.1 上车量空间分布图




图 5 2025 年 10 月纽约市黄色出租车上车量空间分布图

图中展示了 2025 年 10 月纽约市黄色出租车上车量在 Taxi Zone 分区尺度上的空间分布。颜色越深表示该分区上车量越高，颜色越浅表示上车量越低。

从图中可以看出，纽约市黄色出租车上车热点高度集中于曼哈顿核心区，尤其是 Midtown Center、Upper East Side South、Upper East Side North、Times Sq/Theatre District、Union Sq、Penn Station/Madison Sq West 等区域。同时，JFK Airport 和 LaGuardia Airport 也表现出明显高值，说明机场接驳是黄色出租车上车需求的重要来源。

该图说明，黄色出租车上车需求并非均匀分布，而是与商务办公、商业消费、旅游接待和交通枢纽功能密切相关。曼哈顿核心区因城市活动密度高、功能复合程度强，成为最主要的出租车出发热点。

表 7 上车量前 10 位分区统计表

LocationID	行政区	分区名称	上车量	下车量	POI 总量
237	Manhattan	Upper East Side South	194,813	177,268	52
161	Manhattan	Midtown Center	181,787	150,598	91
132	Queens	JFK Airport	175,475	34,722	21
236	Manhattan	Upper East Side North	169,973	176,501	74
162	Manhattan	Midtown East Penn	130,430	111,817	59
186	Manhattan	Station/Madison Sq West	128,080	86,147	38
142	Manhattan	Lincoln Square East Times	125,902	110,376	60
230	Manhattan	Sq/Theatre District	124,068	116,292	111
138	Queens	LaGuardia Airport	116,319	41,247	19
234	Manhattan	Union Sq	109,720	99,091	105

7.2 下车量空间分布图




图 6 2025 年 10 月纽约市黄色出租车下车量空间分布图

下车量空间分布图反映了各 Taxi Zone 分区作为出租车目的地的活动强度。图中颜色越深，表示该分区下车量越高。

从空间格局看，下车高值区同样集中于曼哈顿核心区。Upper East Side South、Upper East Side North、Midtown Center、Times Sq/Theatre District、Murray Hill、East Chelsea 等区域下车量较高，说明这些区域不仅是出租车主要出发地，也是重要目的地。

对比上车量和下车量图可以发现，二者空间格局高度相似，说明纽约市黄色出租车的起点热点和终点热点具有较强重合性。这一现象反映出曼哈顿核心区具有高度复合的城市功能，既吸引人口进入，也产生大量出发需求。结合后续相关性分析，上车量与下车量的 Pearson 相关系数达到 0.949，进一步证明了这种空间重合特征。

表 8 下车量前 10 位分区统计表

LocationID	行政区	分区名称	上车量	下车量	POI 总量
237	Manhattan	Upper East Side South	194,813	177,268	52
236	Manhattan	Upper East Side North	169,973	176,501	74
161	Manhattan	Midtown Center Times	181,787	150,598	91
230	Manhattan	Sq/Theatre District	124,068	116,292	111
170	Manhattan	Murray Hill	109,217	113,905	89
162	Manhattan	Midtown East	130,430	111,817	59
142	Manhattan	Lincoln Square East	125,902	110,376	60
68	Manhattan	East Chelsea	105,373	105,088	83
239	Manhattan	Upper West Side South	103,753	104,706	93
141	Manhattan	Lenox Hill West	88,691	99,861	76

7.3 高频 OD 流向图

上车量前 10 位和下车量前 10 位分区均高度集中于曼哈顿核心区。其中 Upper East Side South、Upper East Side North、Midtown Center、Times Sq/Theatre District、Midtown East 等分区既是主要出发地，也是主要目的地。这说明纽约市黄色出租车的上车热点与下车热点高度重合，反映核心城市活动区具有复合型功能。




图 7 2025 年 10 月纽约市黄色出租车高频 OD 流向前 10 位图

OD 前 10 位流向主要集中于曼哈顿核心区内部。Upper East Side South 与 Upper East Side North 之间的双向流动最强，说明上东区内部及其与中城之间存在大量短距离、高频次的点到点出行。OD 分析不仅揭示交通流动强度，也反映了城市功能区之间的联系。

表 9 高频 OD 流向前 10 位

起点 ID	起点分区	终点 ID	终点分区	OD 流量
237	Upper East Side South	236	Upper East Side North	28,881
236	Upper East Side North	237	Upper East Side South	24,689
237	Upper East Side South	237	Upper East Side South	19,181
236	Upper East Side North	236	Upper East Side North	16,978
161	Midtown Center	237	Upper East Side South	13,392
237	Upper East Side South	161	Midtown Center	12,480
161	Midtown Center	236	Upper East Side North	10,792
237	Upper East Side South	162	Midtown East	9,756
236	Upper East Side North	161	Midtown Center	9,474
142	Lincoln Square East	239	Upper West Side South	9,314

7.4 地铁站 POI 空间分布密度图

地铁站 POI 密度图用于反映纽约市轨道交通换乘功能的空间集聚情况。图中高密度区域主要分布在曼哈顿中南部以及部分轨道交通换乘较集中的区域。

从图中可以看出，地铁站密度高值区与部分出租车高值区存在空间邻近关系，说明出租车与轨道交通之间可能存在一定换乘衔接关系。例如，乘客可能在地铁站周边选择出租车完成短距离接驳，也可能在轨道交通不便或夜间服务不足时选择出租车作为补充交通方式。

但从相关性结果看，地铁站数量与上车量、下车量的相关性相对较弱。这说明地铁站数量本身并不能单独解释出租车活动强度，出租车需求还受到商业、旅游、办公、居住和机场接驳等多种因素共同影响。




图 8 纽约市地铁站空间分布密度图

7.5 餐饮商业 POI 空间分布密度图

餐饮商业 POI 密度图反映了纽约市消费服务功能的空间集聚情况。图中高值区主要集中在曼哈顿中城、下城、东村、西村、联合广场和时代广场等商业活动密集区域。

这些区域同时也是出租车上车量和下车量较高的区域，说明商业消费、餐饮服务 and 夜间活动对出租车需求具有明显拉动作用。尤其是在傍晚和夜间时段，餐饮、购物、剧院、娱乐和社交活动会显著增加出租车出行需求，这与前文时间分布中 17—21 时为出租车高峰期的结论相互印证。

因此，餐饮商业 POI 图不仅解释了出租车热点的空间成因，也说明出租车活动与城市消费服务功能之间存在较强耦合关系。




图 9 纽约市餐饮商业点空间分布密度图

7.6 酒店旅游 POI 空间分布密度图

酒店旅游 POI 密度图用于反映旅游接待和住宿服务功能的空间分布。图中高密度区主要集中于 Times Sq/Theatre District、Midtown、Financial District North 以及部分旅游活动较集中的区域。

从结果看，酒店旅游点高值区与出租车下车高值区具有较强一致性。酒店、景点和旅游接待区域通常具有较强目的地吸引力，游客到达、酒店入住、景点访问和商务差旅均可能增加出租车下车需求。

相关性分析也表明，酒店旅游点数量与出租车活动强度的相关性最高，其中与上车量相关系数为 0.532，与下车量相关系数为 0.570。说明旅游住宿和目的地访问是影响纽约黄色出租车空间分布的重要因素。




图 10 纽约市酒店旅游点空间分布密度图

7.7 POI 数量对比图

POI 数量对比图展示了 2025 年 10 月纽约市黄色出租车起点分区与终点分区之间的主要联系。通过统计 PULocationID 与 DOLocationID 的组合关系，可以识别出订单数量最高的 OD 流向。

从数量对比结果看，前 10 位流向主要集中于曼哈顿核心区内部。其中，Upper East Side South 与 Upper East Side North 之间的双向联系最强，Midtown Center、Midtown East、Lincoln Square East、Upper West Side South 等区域之间也存在明显高频流动。

该图说明，黄色出租车并不只是承担机场接驳或长距离出行，也承担了大量核心城区内部的短距离、高频次、点到点流动。这类流动反映了曼哈顿核心功能区之间的紧密联系，也体现了出租车在高密度城市空间中的补充交通作用。

纽约市黄色出租车上车量前10分区与 POI 类型对比




图 11 上车量前 10 分区与 POI 数量对比图

纽约市黄色出租车下车量前10分区与 POI 类型对比




图 12 下车量前 10 分区与 POI 数量对比图

7.8 相关性矩阵热力图

相关性矩阵热力图用于量化出租车活动强度与不同 POI 类型之间的关系。本文选取上车量、下车量、地铁站数量、餐饮商业点数量、酒店旅游点数量和 POI 总量作为变量，计算 Pearson 相关系数。

结果显示，上车量与下车量之间相关性最强，相关系数达到 0.949，说明起点热点与终点热点高度重合。三类 POI 中，酒店旅游点与出租车活动强度相关性最高，餐饮商业点次之，地铁站数量相关性较弱。

这一结果说明，出租车热点形成不是由单一交通设施决定的，而是受到旅游住宿、商业消费、办公服务和综合城市功能共同影响。相关性矩阵热力图使原本依靠地图观察得到的空间关系转化为定量证据，增强了分析结论的可靠性。




图 13 出租车活动强度与 POI 类型相关性矩阵热力图




图 14 POI 类型与上车量/下车量相关系数对比图

相关性矩阵结果显示，上车量与下车量相关系数达到 0.949，属于极强正相关。在三类 POI 中，酒店旅游点数量与出租车活动强度相关性最高，餐饮商业点次之，地铁站数量与出租车活动的相关性较弱。这说明出租车热点并非单纯由轨道交通站点数量决定，而更多受到旅游住宿、商业消费、办公服务和综合功能集聚影响。

7.9 典型功能区空间识别图

为了更好体现题目中的“功能区差异分析”，本文基于 POI 结构和出租车活动强度，将纽约市典型 Taxi Zone 分为交通枢纽区、商业餐饮功能区、酒店旅游功能区、综合功能区和一般功能区。

从功能区空间识别结果看，综合功能区主要集中在曼哈顿核心区，包括 Midtown Center、Times Sq/Theatre District、Union Sq、Midtown East、Upper East Side South 等区域。这些区域同时具有较高上车量、下车量 and 多类型 POI 集聚特征，是纽约市出租车活动最强、城市功能最复合的区域。

交通枢纽区主要包括 JFK Airport、LaGuardia Airport 和 Penn Station/Madison Sq West 等区域，出租车在这些区域主要承担机场、铁路和城市内部之间的接驳功能。商业餐饮功能区和酒店旅游功能区则更多分布在曼哈顿中南部及部分活跃街区，反映消费服务和旅游接待功能对出租车需求的拉动作

用。

因此，功能区空间识别图进一步说明，出租车活动并不是随机分布的，而是与城市功能区结构密切相关，表现出明显的功能导向型空间集聚特征。




图 15 纽约市典型功能区空间识别图




图 16 不同典型功能区平均出租车活动强度对比图




图 17 典型功能分区出租车活动强度对比图




图 18 典型功能分区 POI 结构对比图

表 10 不同典型功能区平均出租车活动强度

功能区类型	上车量	下车量	出租车活动总量	POI 总量
交通枢纽区	85,413	36,361	121,774	41.000
商业餐饮功能区	59,688	55,069	114,757	178.000
综合功能区	148,164	131,013	279,177	84.000
酒店旅游功能区	54,517	53,256	107,773	84.000

典型功能区对比结果表明，综合功能区和酒店旅游功能区的出租车活动强度整体较高。交通枢纽区中，JFK Airport 和 LaGuardia Airport 上车量明显高于下车量，体现机场接驳需求；商业餐饮功能区中，East Village、Clinton East 和 West Village 等区域餐饮商业点数量较多，说明消费服务业具有明显出行拉动作用；综合功能区中，Midtown Center、Times Sq/Theatre District、Union Sq 和 Upper East Side South 同时具有较高出租车活动强度和多类型 POI 集聚，是城市功能复合度最高的区域。

八、结论与展望

通过本次平时作业，可以形成以下结论。第一，从时间维度看，纽约市黄色出租车活动具有显著昼夜周期，凌晨 2—5 时为低谷，17—21 时为高峰，18 时达到全天峰值。该结果说明出租车订单数据能够较好反映城市活动时间节律。

第二，从空间维度看，纽约市黄色出租车活动呈现明显中心集聚格局。曼哈顿中城、上东区、时代广场、联合广场、切尔西、宾州车站周边以及 JFK Airport、LaGuardia Airport 是主要高值区，而史泰登岛和部分外围区域订单量相对较低。

第三，从 OD 流向看，高频 OD 主要集中在曼哈顿核心区内部，尤其是 Upper East Side South、Upper East Side North、Midtown Center 和 Midtown East 等分区之间。这表明黄色出租车在纽约核心城区承担了大量短距离、高频次、点到点的城市内部流动。

第四，从功能区差异看，POI 分析能够有效解释出租车热点形成机制。酒店旅游点和餐饮商业点与出租车活动强度呈中等正相关，说明旅游住宿、商业消费和综合服务功能是形成出租车热点的重要因素。交通枢纽区虽然 POI 总量不一定最高，但由于机场、铁路和换乘功能突出，仍能产生显著出租车接驳需求。

第五，从技术实践看，本作业完成了从 Parquet 大数据读取、异常值清洗、时空字段构建、分区统计、OD 统计、POI 空间连接到专题地图和动态可视化输出的完整流程。该流程具有较强的可复用性，可以迁移到共享单车、网约车、公交刷卡、手机信令等其他城市时空大数据分析场景。

本作业也存在一些不足。首先，研究时段主要为 2025 年 10 月一个月，尚未充分讨论季节差异和长期变化趋势；其次，空间单元采用 Taxi Zone，可能存在可变空间单元问题，未来可尝试规则网格、街区或道路网络尺度；再次，POI 数据来自 OSM，可能存在标签不一致和覆盖不均问题，后续可引入官方土地利用、商业登记、酒店房间数量、地铁客流和人口栅格数据；最后，服务均衡性分

析目前以面积归一化为主，未来可进一步结合常住人口、就业人口和游客量，构建更完善的公平性评价指标。

九、主要成果文件与代码说明

表 11 主要成果文件说明

成果文件	内容说明	用途
pickup_by_zone.csv	分区上车量统计表	ArcGIS 上车量专题图、Top10 表
dropoff_by_zone.csv	分区下车量统计表	ArcGIS 下车量专题图、Top10 表
hourly_orders.csv	24 小时订单量表	小时变化折线图
weekday_hour_orders.csv	星期—小时订单量表	工作日—小时多折线图
od_top100.csv	高频 OD 流向表	OD 前 10 图与流向分析
纽约市出租车活动强度与 POI 类型分区对比表.csv	出租车强度与 POI 汇总表	相关性矩阵、功能区分析
纽约市典型功能分区出租车活动强度对比表.csv	典型功能区对比表	功能区差异分析
上车.jpg、下车.jpg	上车/下车空间分布图	空间热点识别
subwayPOI.jpg、foodPOI.jpg、hotelPOI.jpg	三类 POI 密度图	功能要素解释

为了便于复现，完整代码可分为“数据清洗统计代码”和“小时级 OD 动图代码”两部分。其中，数据清洗统计代码负责生成所有 CSV 统计表；小时级 OD 动图代码负责读取完整订单数据和 taxi_zones.shp，按 0—23 小时统计 OD 网络并输出 GIF 动图。本报告正文中已列出关键代码片段，实际运行时需要保证 Python 环境中安装 pandas、pyarrow、numpy、pyshp、shapely 和 pillow 等依赖。

总体而言，本平时作业不仅完成了专题地理时空大数据的获取、清洗、处理和统计，也形成了较完整的代码流程、空间图件和统计图表成果，为后续结课大作业和汇报展示奠定了基础。

参考资料

- [1] New York City Taxi and Limousine Commission. TLC Trip Record Data.
- [2] New York City Taxi and Limousine Commission. Data Dictionary - Yellow Taxi Trip Records, 2025.
- [3] OpenStreetMap Wiki. Overpass API.
- [4] OpenStreetMap Wiki. Overpass turbo / GeoJSON.
- [5] 边馥苓. 时空大数据的技术与方法[M]. 北京: 测绘出版社, 2016.
- [6] 钟耳顺等. 大数据地理信息系统原理、技术与应用[M]. 北京: 清华大学出版社, 2021.
- [7] 秦艺帆等. 地图时空大数据爬取与规划分析教程[M]. 南京: 东南大学出版社, 2019.
- [8] 黄源等. 数据清洗[M]. 北京: 清华大学出版社, 2021.

附录：数据清洗 python 代码

```
import pandas as pd
import os
# =====
# 1. 路径设置
# =====
# 把这里改成你自己的数据文件夹路径
data_dir = r"D:\专业课\地理时空信息大数据\data_raw"
trip_file = os.path.join(data_dir, "yellow_tripdata_2025-10.parquet")
lookup_file = os.path.join(data_dir, "taxi_zone_lookup.csv")
output_dir = os.path.join(data_dir, "outputs")
os.makedirs(output_dir, exist_ok=True)
# =====
# 2. 读取数据
# =====
use_cols = [
    "tpep_pickup_datetime",
    "tpep_dropoff_datetime",
    "PULocationID",
    "DOLocationID",
    "trip_distance",
    "passenger_count",
    "payment_type",
    "fare_amount",
    "tip_amount",
    "total_amount"
]
print("正在读取 parquet 数据...")
df = pd.read_parquet(trip_file, columns=use_cols)
print("原始数据量: ", len(df))
print(df.head())
# =====
# 3. 基础清洗
# =====
# 时间转为 datetime
df["tpep_pickup_datetime"] = pd.to_datetime(df["tpep_pickup_datetime"], errors="coerce")
df["tpep_dropoff_datetime"] = pd.to_datetime(df["tpep_dropoff_datetime"], errors="coerce")
# 删除关键字段缺失
df = df.dropna(subset=[
    "tpep_pickup_datetime",
    "tpep_dropoff_datetime",
    "PULocationID",
    "DOLocationID",
    "trip_distance",
    "total_amount"
])
# 保证 LocationID 为整数
df["PULocationID"] = df["PULocationID"].astype(int)
df["DOLocationID"] = df["DOLocationID"].astype(int)
```



```

# 行程时长 (分钟)
df["trip_duration_min"] = (
    df["tpep_dropoff_datetime"] - df["tpep_pickup_datetime"]
).dt.total_seconds() / 60
# 剔除明显异常值
df = df[df["trip_duration_min"] > 0]
df = df[df["trip_distance"] > 0]
df = df[df["total_amount"] > 0]
# 进一步剔除极端异常值 (可按需要调整)
df = df[df["trip_duration_min"] <= 180] # 最长 3 小时
df = df[df["trip_distance"] <= 100]    # 最长 100 英里
df = df[df["total_amount"] <= 500]    # 总费用不超过 500 美元
print("清洗后数据量: ", len(df))
# =====
# 4. 构造时间字段
# =====
df["pickup_date"] = df["tpep_pickup_datetime"].dt.date
df["pickup_hour"] = df["tpep_pickup_datetime"].dt.hour
df["pickup_weekday"] = df["tpep_pickup_datetime"].dt.dayofweek # 周一=0, 周日=6
df["pickup_weekday_name"] = df["tpep_pickup_datetime"].dt.day_name()
df["is_weekend"] = df["pickup_weekday"].isin([5, 6]).astype(int)
# =====
# 5. 读取分区对照表
# =====
lookup = pd.read_csv(lookup_file)
# 统一列名, 防止不同版本字段名有差异
lookup.columns = [c.strip() for c in lookup.columns]
# 常见 lookup 字段一般是:
# LocationID, Borough, Zone, service_zone
print("lookup 字段: ", lookup.columns.tolist())
# =====
# 6. 各分区上车量统计
# =====
pickup_by_zone = (
    df.groupby("PULocationID")
      .size()
      .reset_index(name="pickup_count")
      .rename(columns={"PULocationID": "LocationID"})
)
pickup_by_zone = pickup_by_zone.merge(lookup, on="LocationID", how="left")
pickup_by_zone = pickup_by_zone.sort_values("pickup_count", ascending=False)
pickup_by_zone.to_csv(
    os.path.join(output_dir, "pickup_by_zone.csv"),
    index=False,
    encoding="utf-8-sig"
)
# =====
# 7. 各分区下车量统计
# =====
dropoff_by_zone = (
    df.groupby("DOLocationID")
      .size()

```

```

        .reset_index(name="dropoff_count")
        .rename(columns={"DOLocationID": "LocationID"})
    )
    dropoff_by_zone = dropoff_by_zone.merge(lookup, on="LocationID", how="left")
    dropoff_by_zone = dropoff_by_zone.sort_values("dropoff_count", ascending=False)
    dropoff_by_zone.to_csv(
        os.path.join(output_dir, "dropoff_by_zone.csv"),
        index=False,
        encoding="utf-8-sig"
    )
# =====
# 8. 24 小时订单量统计
# =====
hourly_orders = (
    df.groupby("pickup_hour")
      .size()
      .reset_index(name="order_count")
      .sort_values("pickup_hour")
)
hourly_orders.to_csv(
    os.path.join(output_dir, "hourly_orders.csv"),
    index=False,
    encoding="utf-8-sig"
)
# =====
# 9. 星期-小时二维统计
# =====
weekday_hour_orders = (
    df.groupby(["pickup_weekday", "pickup_weekday_name", "pickup_hour"])
      .size()
      .reset_index(name="order_count")
      .sort_values(["pickup_weekday", "pickup_hour"])
)
weekday_hour_orders.to_csv(
    os.path.join(output_dir, "weekday_hour_orders.csv"),
    index=False,
    encoding="utf-8-sig"
)
# =====
# 10. OD 流向统计 (前100)
# =====
od_table = (
    df.groupby(["PULocationID", "DOLocationID"])
      .size()
      .reset_index(name="flow_count")
      .sort_values("flow_count", ascending=False)
)
# 给起点终点加名称
lookup_from = lookup.rename(columns={
    "LocationID": "PULocationID",
    "Borough": "PU_Borough",
    "Zone": "PU_Zone",
    "service_zone": "PU_service_zone"

```

```

})
lookup_to = lookup.rename(columns={
    "LocationID": "DOLocationID",
    "Borough": "DO_Borough",
    "Zone": "DO_Zone",
    "service_zone": "DO_service_zone"
})
od_table = od_table.merge(lookup_from, on="PULocationID", how="left")
od_table = od_table.merge(lookup_to, on="DOLocationID", how="left")
od_top100 = od_table.head(100)
od_top100.to_csv(
    os.path.join(output_dir, "od_top100.csv"),
    index=False,
    encoding="utf-8-sig"
)
# =====
# 11. 导出一份清洗后的样本，方便检查
# =====
sample = df.sample(min(5000, len(df)), random_state=42)
sample.to_csv(
    os.path.join(output_dir, "cleaned_tripdata_sample.csv"),
    index=False,
    encoding="utf-8-sig"
)
# =====
# 12. 控制台输出结果预览
# =====
print("\n==== 输出完成 =====")
print("输出文件夹: ", output_dir)
print("\n上车量 Top 10: ")
print(pickup_by_zone.head(10))
print("\n下车量 Top 10: ")
print(dropoff_by_zone.head(10))
print("\n24 小时订单量: ")
print(hourly_orders)
print("\nOD Top 10: ")
print(od_top100.head(10))

```