

东北大学资源与土木工程学院

技 术 报 告

课程名称：地理时空信息大数据

学生专业：测绘工程

学生班级：测绘 2301

学 号：20232444

学生姓名：闻子博

指导教师：郭甲腾 舒阳

作业成绩：

教师评语：

评阅人：

评阅时间：

目录

一、技术报告目的与总体流程	1
二、数据获取与文件组织	1
三、订单数据清洗与质量控制	3
四、分区聚合、时间统计与 OD 矩阵构建	4
五、Python 图表生成流程	6
5.1 时间统计图生成	6
5.2 POI 对比图与 OD 图生成	6
5.3 相关性矩阵与功能区图表生成	8
六、ArcGIS 10.2 专题制图流程	10
6.1 上车量与下车量专题图	10
6.2 POI 核密度图	12
七、空间连接、POI 统计与功能区识别	13
7.1 Spatial Join 统计 POI 数量	13
7.2 典型功能区空间识别图制作	13
八、面积归一化服务密度计算与制图	14
九、成果文件与代码说明	15
十、问题处理与技术总结	15

一、技术报告目的与总体流程

本报告面向“地理时空信息大数据”课程平时作业要求，围绕“开展专题地理时空大数据的获取、清洗、处理、统计等工作，完成代码编写及作业报告撰写”的任务展开。研究对象为 2025 年 10 月纽约市黄色出租车订单数据，技术重点不再仅是展示最终结论，而是详细说明从原始数据到统计表、专题地图和可视化图表的完整实现过程。

整体技术路线包括五个层次：第一，获取 TLC 出租车订单、Taxi Zone 空间分区、Taxi Zone Lookup 对照表和 OSM POI 数据；第二，使用 Python 读取 Parquet 订单数据，进行字段筛选、时间解析、异常值剔除和派生字段构建；第三，基于 PULocationID 和 DOLocationID 进行分区统计，生成上车量、下车量、小时订单量、星期-小时订单量和 OD 流向表；第四，在 ArcGIS 10.2 中完成分级设色、空间连接、核密度、面积计算和功能识别制图；第五，使用 Python 生成折线图、柱状图、相关性矩阵、OD 图和动图等可视化成果。

表 1 技术流程与成果输出

阶段	关键操作	输出成果	主要工具
数据获取	下载 TLC 订单、Taxi Zone、OSM POI	原始数据文件夹	浏览器、Overpass Turbo
数据清洗	缺失值剔除、异常距离/费用/时长过滤	清洗后有效订单	Python pandas
统计处理	分区聚合、小时统计、星期统计、OD 统计	CSV 统计表	Python pandas
空间制图	属性连接、分级设色、空间连接、核密度	专题地图	ArcGIS 10.2
图表生成	折线图、柱状图、热力图、OD 图、动图	PNG/GIF 图表	Python matplotlib/Pillow

二、数据获取与文件组织

本研究使用的数据包括核心订单数据、空间分区数据和辅助功能要素数据三类。核心订单数据为 TLC 发布的 2025 年 10 月黄色出租车订单，格式为 Parquet，具有数据量大、读取效率高、字段结构明确等特点。空间分区数据为 taxi_zones.shp，用于

表示纽约市出租车管理分区。辅助数据为 OSM POI，包括地铁站、餐饮商业点、酒店旅游点，用于解释出租车热点形成的功能区差异。

表 2 数据文件与用途

数据名称	文件名	核心字段/内容	用途
黄色出租车订单	yellow_tripdata_2025-10.parquet	上车时间、下车时间、PULocationID、DOLocationID、距离、费用	清洗、时间统计、OD统计
Taxi Zone 对照表	taxi_zone_lookup.csv	LocationID、Borough、Zone、service_zone	编号与分区名称匹配
Taxi Zone 空间面	taxi_zones.shp	分区面边界、LocationID/zone 字段	专题地图、面积计算、空间连接
地铁站 POI	nyc_subway_station.geojson/shp	点位与交通标签	交通功能解释
餐饮商业 POI	nyc_food_shop.geojson/shp	餐饮、咖啡、商店等点位	商业消费功能解释
酒店旅游 POI	nyc_hotel_tourism.geojson/shp	酒店、景点等点位	旅游接待功能解释

建议将所有文件统一放入项目目录，并按 raw、outputs、figures、arcgis_workspace 等子文件夹组织。这样能够保证代码路径清晰、成果文件便于检查，也方便提交作业时说明数据处理流程。

```
project_root/  
  yellow_tripdata_2025-10.parquet  
  taxi_zone_lookup.csv  
  taxi_zones/  
    taxi_zones.shp / .dbf / .shx / .prj / .cpg  
  nyc_subway_station.geojson  
  nyc_food_shop.geojson  
  nyc_hotel_tourism.geojson  
  outputs/  
    pickup_by_zone.csv  
    dropoff_by_zone.csv  
    hourly_orders.csv  
    weekday_hour_orders.csv  
    od_top100.csv  
  figures/  
    各类统计图与专题图
```

三、订单数据清洗与质量控制

出租车订单属于典型的事件型时空大数据。每一条订单记录都包含起止时间、起止空间单元、行程距离和费用等属性。由于数据量较大，直接将原始数据用于统计可能受到异常订单影响，因此必须先完成质量控制。本研究的清洗原则是保留真实有效的出行记录，剔除明显不符合逻辑的记录，并尽量避免过度清洗导致样本偏差。

表 3 订单数据清洗规则

清洗对象	处理规则	技术含义
关键字段缺失	删除上下车时间、LocationID、距离、费用为空的记录	保证订单可用于时间和空间统计
行程时长异常	<code>trip_duration_min <= 0</code> 的记录剔除	避免错误时间差和系统异常
行程距离异常	<code>trip_distance <= 0</code> 的记录剔除	去除无效订单或测试记录
费用异常	<code>total_amount <= 0</code> 的记录剔除	去除异常收费或无效记录
极端值控制	时长≤180 分钟、距离≤100 英里、费用≤500 美元	降低极端异常值对统计图表影响
分区编号控制	PULocationID 和 DOLocationID 限定在 1—263	保证能够与 Taxi Zone 空间数据匹配

行程时长字段由上下车时间差计算得到，计算公式如下：

$$trip_{duration_{min}} = \frac{(tpep_{dropoff_{datetime}} - tpep_{pickup_{datetime}})}{60}$$

其中时间差原始单位为秒，除以 60 后转换为分钟。清洗后共保留有效订单 4,135,152 条，能够支撑后续时空统计与空间制图。

Python 清洗代码的核心逻辑如下，完整代码见附件代码包中的 01_clean_and_aggregate.py。

```
df["trip_duration_min"] = (
    df["tpep_dropoff_datetime"] - df["tpep_pickup_datetime"]
).dt.total_seconds() / 60

rules = (
    (df["trip_duration_min"] > 0) &
    (df["trip_distance"] > 0) &
    (df["total_amount"] > 0) &
    (df["trip_duration_min"] <= 180) &
    (df["trip_distance"] <= 100) &
    (df["total_amount"] <= 500) &
```

```

(df["PULocationID"].between(1, 263)) &
(df["DOLocationID"].between(1, 263))
)
df = df.loc[rules].copy()

```

四、分区聚合、时间统计与 OD 矩阵构建

纽约 TLC 订单数据已经提供上车分区编号 PULocationID 和下车分区编号 DOLocationID，因此不需要对每条订单进行经纬度点落区。分区统计的关键是将订单编号与 Taxi Zone Lookup 中的 LocationID 进行匹配，从而得到每个分区的行政区、分区名称和服务区。

分区上车量、下车量和 OD 流量可表示为：

$$T_i^{PU} = \text{count}(PULocationID = i)$$

$$T_i^{DO} = \text{count}(DOLocationID = i)$$

$$F_{ij} = \text{count}(PULocationID = i, DOLocationID = j)$$

其中， T_i^{PU} 表示第 i 个分区的上车量， T_i^{DO} 表示第 i 个分区的下车量， F_{ij} 表示从分区 i 到分区 j 的 OD 流量。

表 4 统计表输出说明

输出表	生成方式	字段示例	后续用途
pickup_by_zone.csv	按 PULocationID 分组计数	LocationID、 pickup_count、Borough、 Zone	上车热点制图
dropoff_by_zone.csv	按 DOLocationID 分组计数	LocationID、 dropoff_count、 Borough、Zone	下车热点制图
hourly_orders.csv	按 pickup_hour 分组计数	pickup_hour、order_count	24 小时折线图
weekday_hour_orders.csv	按星期和小时分组计数	weekday、hour、 order_count	工作日—小时多折线图
od_top100.csv	按起终点分区组合计数并 排序	PU_Zone、DO_Zone、 flow_count	OD 高频流向图




图 1 24 小时订单量变化图




图 2 工作日一小时订单量变化图

时间统计图表由 02_time_charts.py 生成。该脚本先读取 hourly_orders.csv 绘制 24 小时折线图，再将 weekday_hour_orders.csv 透视为“小时×星期”的矩阵，绘制多折线图，用于分析工作日与周末差异。

五、Python 图表生成流程

Python 图表主要用于统计结果展示，包括时间曲线、POI 对比图、OD 高频流向图、相关性矩阵热力图和典型功能区对比图。图表生成的基本流程是：读取 CSV/Excel 统计表，整理绘图字段，调用 matplotlib 绘图，最后以 PNG 格式输出。

5.1 时间统计图生成

24 小时折线图用于描述全天订单变化规律；工作日—小时多折线图用于比较不同星期在各小时的需求差异。其核心代码如下：

```
hourly = pd.read_csv("hourly_orders.csv")
plt.plot(hourly["pickup_hour"], hourly["order_count"], marker="o")
plt.xlabel("小时")
plt.ylabel("订单量")
plt.title("2025 年 10 月纽约市黄色出租车 24 小时订单量变化图")
plt.savefig("24 小时订单量变化图.png", dpi=300)

wh = pd.read_csv("weekday_hour_orders.csv")
pivot = wh.pivot(index="pickup_hour", columns="pickup_weekday_name",
values="order_count")
for col in pivot.columns:
    plt.plot(pivot.index, pivot[col], marker="o", label=col)
plt.legend()
plt.savefig("工作日小时订单量变化图.png", dpi=300)
```

5.2 POI 对比图与 OD 图生成

上车量和下车量前 10 分区 POI 对比图使用堆叠柱状图表示地铁站、餐饮商业点和酒店旅游点数量。OD 高频流向图使用横向柱状图表示前 10 条 OD 流量。

纽约市黄色出租车上车量前10分区与 POI 类型对比




图 3 上车量前 10 分区与 POI 数量对比图

纽约市黄色出租车下车量前10分区与 POI 类型对比




图 4 下车量前 10 分区与 POI 数量对比图




图 5 OD 高频流向前 10 位图

5.3 相关性矩阵与功能区图表生成

相关性矩阵用于定量评估出租车活动强度与不同 POI 类型之间的关系。本文使用 Pearson 相关系数，公式为：

$$r_{xy} = \frac{\Sigma(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{[\Sigma(x_i - \bar{x})^2 \cdot \Sigma(y_i - \bar{y})^2]}}$$




图 6 出租车活动强度与 POI 类型相关性矩阵热力图




图 7 不同典型功能区平均出租车活动强度对比图

六、ArcGIS 10.2 专题制图流程

ArcGIS 10.2 主要承担空间表达和专题地图制作任务。与 Python 图表相比, ArcGIS 更适合处理分区面、点图层空间连接、核密度制图、地图布局、图例、比例尺和指北针等地图制图环节。

表 5 ArcGIS 专题图制作流程

图件类型	输入数据	关键工具/操作	符号化方法
上车量空间分布图	taxi_zones.shp + pickup_by_zone.csv	属性连接 Join	Quantities → Graduated colors
下车量空间分布图	taxi_zones.shp + dropoff_by_zone.csv	属性连接 Join	Quantities → Graduated colors
POI 密度图	三类 POI 点图层	Kernel Density	栅格分级设色
POI 分区统计图	taxi_zones.shp + POI 点	Spatial Join	Join_Count 字段分级
功能区空间识别图	taxi_zones.shp	新增 fun_type 字段并分类 赋值	Categories → Unique values
服务密度图	taxi_zones.shp + 面积字 段 + 订单量	计算几何、字段计算器	密度字段分级设色

6.1 上车量与下车量专题图

具体操作流程为：第一，启动 ArcMap 并加载 taxi_zones.shp；第二，将 pickup_by_zone.csv 作为表格添加到 ArcMap；第三，右键 taxi_zones 图层，选择 Joins and Relates → Join，根据 LocationID 进行属性连接；第四，在图层属性中选择 Symbolology → Quantities → Graduated colors，以 pickup_count 字段进行分级设色；第五，进入 Layout View，添加标题、图例、比例尺和指北针，最后导出 300 dpi PNG 图片。下车量图操作相同，只需连接 dropoff_by_zone.csv 并以 dropoff_count 字段设色。




图 8 上车量空间分布图




图 9 下车量空间分布图

6.2 POI 核密度图

POI 核密度图用于表达点要素的空间集聚强度。ArcGIS 10.2 中可在 ArcToolbox 中选择 Spatial Analyst Tools → Density → Kernel Density。输入点图层分别选择地铁站、餐饮商业点和酒店旅游点；输出像元大小和搜索半径可根据地图比例尺设置；生成栅格后使用分级颜色表达密度差异。




图 10 地铁站 POI 空间分布密度图




图 11 餐饮商业 POI 空间分布密度图




图 12 酒店旅游 POI 空间分布密度图

七、空间连接、POI 统计与功能区识别

POI 数据的核心作用是解释出租车热点形成机制。为了把点状 POI 转化为分区级解释变量，需要使用 ArcGIS 空间连接工具，将每个 Taxi Zone 内部的 POI 数量统计出来。

7.1 Spatial Join 统计 POI 数量

在 ArcGIS 10.2 中打开 ArcToolbox → Analysis Tools → Overlay → Spatial Join。Target Features 选择 taxi_zones，Join Features 选择 POI 点图层，Join Operation 选择 JOIN_ONE_TO_ONE，Keep All Target Features 选择 KEEP_ALL，Match Option 选择 INTERSECT。输出图层属性表中的 Join_Count 字段即表示每个分区内的 POI 数量。该过程分别对地铁站、餐饮商业点和酒店旅游点执行一次。

7.2 典型功能区空间识别图制作

为体现题目中的“功能区差异分析”，需要在 Taxi Zone 图层中新建 fun_type 字段，并将典型分区划分为 Transport、Commercial、Tourism、Mixed 和 General 五类。ArcMap 中先将所有分区字段计算为 General，再按 Zone 名称选择典型分区，分别赋值为交通枢纽区、商业餐饮功能区、酒店旅游功能区和综合功能区，最后使用 Categories → Unique values 按 fun_type 字段分类着色。

表 6 典型功能区分类规则

功能区类型	典型分区示例	空间含义
交通枢纽区	JFK Airport、LaGuardia Airport、Penn Station/Madison Sq West	机场、铁路和换乘接驳需求突出
商业餐饮功能区	East Village、West Village、Clinton East、East Chelsea	消费、餐饮和夜间活动密集
酒店旅游功能区	Times Sq/Theatre District、Midtown South、Financial District North	旅游住宿和目的地访问需求强
综合功能区	Midtown Center、Midtown East、Union Sq、Upper East Side South	商务、商业、旅游、居住功能复合
一般功能区	其他 Taxi Zone	未归入典型功能区的普通分区




图 13 典型功能分区 POI 结构对比图

八、面积归一化服务密度计算与制图

订单总量容易受到分区面积差异影响，因此需要构建单位面积订单量指标。ArcGIS 中先在 taxi_zones 图层添加 area_km2 字段，右键字段选择 Calculate Geometry，单位设置为平方千米；再添加 pickup_den 和 dropoff_den 字段，通过字段计算器计算上车密度和下车密度。

服务密度计算公式为：

$$D_i = T_i / A_i$$

其中 D_i 表示第 i 个分区的出租车服务密度， T_i 表示该分区的上车量或下车量， A_i 表示该分区面积。计算完成后，以 `pickup_den` 和 `dropoff_den` 字段进行分级设色，即可得到面积归一化后的上车服务密度图和下车服务密度图。

表 7 ArcGIS 字段计算说明

字段名	字段类型	计算表达式	含义
area_km2	Double	Calculate Geometry: Area / Square Kilometers	分区面积
pickup_den	Double	[pickup_count] / [area_km2]	单位面积上车量
dropoff_den	Double	[dropoff_count] / [area_km2]	单位面积下车量
fun_type	Text	General/Transport/Commercial/Tourism/Mixed	功能区类别

九、成果文件与代码说明

本次作业提交的代码包括五个 Python 脚本和一个 README 文件。普通数据处理和图表生成建议使用 Python 3 环境运行；ArcPy 自动化示例需要在 ArcGIS 10.2 自带 Python 2.7 环境中运行。

表 8 代码文件说明

代码文件	功能	主要输入	主要输出
01_clean_and_aggregate.py	订单清洗、时间字段构建、分区统计、OD 统计	Parquet 订单、Lookup 表	pickup/dropoff/hourly/weekday/OD CSV
02_time_charts.py	生成时间统计图	hourly_orders、weekday_hour_orders	折线图、星期柱状图
03_poi_od_analysis_charts.py	生成 POI 对比图、OD 图、相关性图和功能区图	POI 分区统计表、OD 表、功能区表	PNG 统计图
04_hourly_od_animation.py	生成小时级 OD 时空演化 GIF	订单数据、shp、Lookup 表	OD 动图 GIF
05_arcgis10_2_arcpy_optional.py	ArcGIS 空间连接、面积计算和功能区分值示例	shp 与 POI 点图层	空间连接结果和字段计算结果

在实际提交时，建议同时提交 Word 技术报告、主要成果图、CSV 统计结果和代码压缩包。若老师只要求核心代码，可优先提交 01—03 号脚本；若需要展示高级时空可视化，则同时提交 04 号动图脚本。

十、问题处理与技术总结

本次技术流程中容易遇到的问题主要包括四类。第一，ArcGIS 10.2 对 GeoJSON 支持较弱，若无法直接加载 OSM 数据，需要先将 GeoJSON 转换为 Shapefile；第二，CSV 与 shp 属性连接时要保证 LocationID 字段类型一致，若一个是文本一个是数值，可能导致 Join 失败；第三，ArcGIS 中字段名不宜过长，shp 字段名建议控制在 10 个

字符以内；第四，OD 动图使用全量数据时线条可能过密，可以设置最小流量阈值，保证视觉表达清晰。

总体来看，本技术报告形成了从原始出租车订单数据到空间统计结果、专题地图和可视化图表的完整流程。该流程体现了地理时空信息大数据处理的典型技术链条：多源数据获取、异常数据清洗、时空字段构建、空间分区聚合、统计指标生成、GIS 专题制图和可视化表达。该方法不仅适用于纽约市出租车订单，也可迁移到共享单车、网约车、公交刷卡、手机信令等其他城市时空大数据应用场景。